



# U-NET 논문 리뷰


바이오 메디컬 이미지 분할을 위한 컨볼루션 네트워크

# Semantic Segmentation



- Semantic Segmentation은 다른 컴퓨터 비전 문제들과 마찬가지로, Deep Convolution Neural Network (깊은 신경망)을 적용해서 많은 발전을 이루었습니다.
- Semantic Segmentation은 컴퓨터 비전 분야에서 가장 핵심적인 분야입니다.
- 그림처럼, 이미지 내에 있는 물체들을 의미 있는 단위로 분할해내는 것입니다.
- 또한 각 픽셀이 어느 클래스에 속하는지 예측해줍니다.

# Introduction




- Network가 U자 형태이기 때문에 UNET이라고 합니다.

- 데이터의 차원이 축소 되었다가 다시 늘어납니다.  
(수축 경로 -> 확장경로)


- 축소 될 때 사용 되었던 신경망이 확장할 때 다시 사용 됩니다.

# Introduction



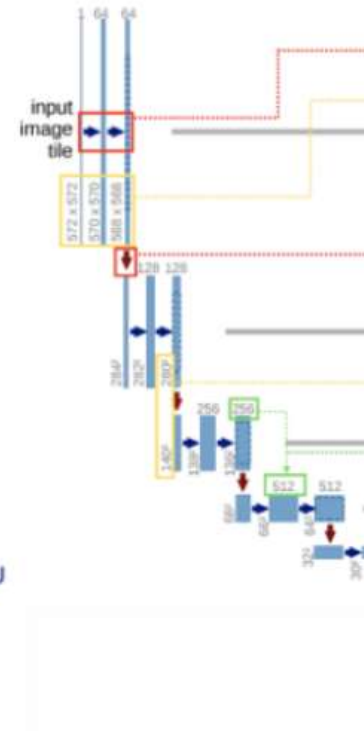
- Conv와 maxpooling을 하면서 데이터의 특징점을 찾아냅니다. (데이터의 차원이 줄어드는 과정)
- Up-conv를 하면서 conv & maxpooling 과정에 사용된 신경망을 붙여 차원축소로 인한 공간 정보 손실을 방지합니다. (데이터 차원이 늘어나는 과정)

# Network Architecture



## Contracting Path

입력 이미지의 Context 포착을 목적으로 구성. FCNs처럼 VGG-based Architecture



## Contracting Path

각 Contracting Step 마다  
3x3 convolution을 두 차례씩 반복  
(단, 패딩이 없음으로 Feature Map이 조금씩 줄어듬)  
Convolution에는 ReLU 연산이 포함됨

각 Contracting Step 마다  
2x2 max-pooling (stride: 2) 연산을 수행함  
이 때, Feature map의 크기가 절반으로 줄어듬

Down-sampling 마다 채널의 수가 2배로 늘어남

- conv 3x3, ReLU
- copy and crop
- ↓ max pool 2x2
- ↑ up-conv 2x2
- conv 1x1

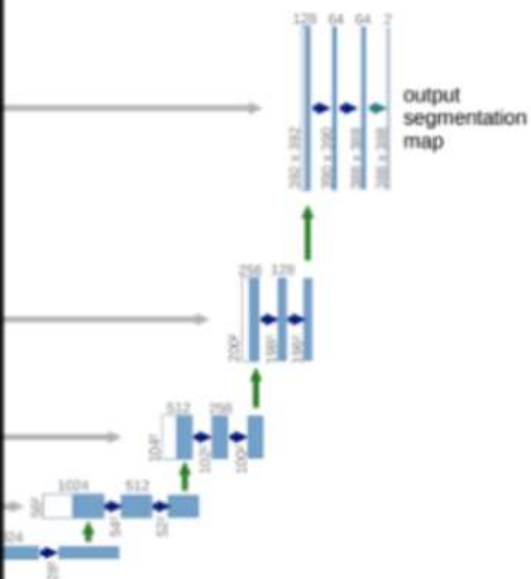
# Network Architecture

## Expanding Path


세밀한 Localization을 위한 구성

높은 차원의 채널을 갖는 Up-sampling

얕은 레이어의 특징맵을 결합



# Network Architecture



- 2 x 2 convolution(up-convolution) : 초록
- 총 23-layers fully convolutional networks
- 최종 출력인 segmentation map의 크기는 input image 크기보다 작다. (conv 연산에서 패딩 사용하지 않아서)

각 Expanding Step 마다  
Up-conv 된 특징맵은 Contracting path의 Cropped된 특징맵과  
Concatenation 함


Skip Architecture

이미지 경계부분 픽셀에 대한 segmentation 을 위해 0이나 임의의 패딩 값을 사용하는 대신 이미지 경계 부분의 미러링을 이용한 extrapolation 기법을 사용하였습니다.




# Data Augmentation

Elastic Deformation



resulting deformed image  
(for visualization: no rotation, no shift, no extrapolation)



correspondingly deformed  
manual labels

- Data augmentation은 갖고 있는 데이터셋을 여러 가지 방법으로 augment하여 실질적인 학습 데이터셋의 규모를 키울 수 있는 방법입니다.
- Coarse 3 X 3 grid에 random displacement vectors을 이용해 smooth deformation을 수행합니다. Displacement는 10개 픽셀이 가지는 값들의 표준편차를 따르는 가우시안 분포에서 임의로 뽑은 값으로 수행합니다.
- Bicubic interpolation을 이용해 픽셀 단위로 displacement를 계산합니다.
- Contracting path의 맨 끝에 있는 Drop out layer가 더욱 implicit한 Data augmentation을 수행합니다.



# Experiments

Rank	Group name	Warping Error	Rand Error	Pixel Error
	** human values **	0.000005	0.0021	0.0010
1.	u-net	<b>0.000353</b>	0.0382	0.0611
2.	DIVE-SCI	0.000355	0.0305	0.0584
3.	IDSIA [1]	0.000420	0.0504	0.0613
4.	DIVE	0.000430	0.0545	<b>0.0582</b>
⋮				
10.	IDSIA-SCI	0.000653	<b>0.0189</b>	0.1027

Name	PhC-U373	DIC-HeLa
IMCB-SG (2014)	0.2669	0.2935
KTH-SE (2014)	0.7953	0.4607
HOUS-US (2014)	0.5323	-
second-best 2015	0.83	0.46
u-net (2015)	<b>0.9203</b>	<b>0.7756</b>

# Conclusion

- U-NET 아키텍처는 매우 다른 생물의학 세분화 애플리케이션에서 매우 우수한 성능을 달성하였습니다. 탄력적인 성능으로 데이터 확대 알고리즘의 저자는 이 결과를 달성하기 위해 78개의 다른 솔루션을 제출하였습니다.
- 뮤테이션은 주석이 달린 이미지가 거의 필요하지 않으며 Nvidia Titan GPU(6GB)에서 10시간의 매우 합리적인 교육 시간을 갖습니다.
- 우리는 완전한 caffe[6] 기반 구현과 훈련된 네트워크를 제공합니다. 우리는 U-NET 아키텍처가 더 많은 작업에 쉽게 적용될 수 있다고 확신합니다.